hackathon
GENERATIVE AI

Challenge proposé par

Nokia

Équipe : 36

- Florian Touraine
- Yann Habié
- Marin Boehm

Lien git :
https://github.com/Styleflo/NokiaCSIprediction

UNIVERSITE PARIS 8 DES CRÉATIONS

UQAC Université du Québec à Chicoutimi

université

1 Pertinence et innovation

1.1 Analyse du besoin et enjeux du secteur

Dans les systèmes de communication modernes comme le Massive MIMO (Multi-in Multi-out), la connaissance précise de l'état du canal est indispensable pour maximiser le débit et l'efficacité. Actuellement, le processus de CSI Feedback (Channel State Information) rencontre deux obstacles majeurs :

- La surcharge : Envoyer des informations détaillées sur le canal consomme une part importante de la bande passante, réduisant ainsi les ressources disponibles pour les données utilisateurs.
- La latence de traitement : Entre le moment où le canal est mesuré et celui où il est utilisé par la station de base, le canal peut avoir changé, rendant l'information obsolète.

Le 3GPP a identifié l'amélioration de ce feedback via le Machine Learning comme une priorité absolue pour les réseaux de demain, 5G et 6G.

1.2 Solutions proposées : Le prédicteur de canal par IA

Pour répondre au défi de la prédiction du canal, notre équipe a développé et comparé plusieurs approches pour répondre au besoin.

1.2.1 Approche de référence : Outdated CSI

Nous avons commencé par implémenter une prédiction simple, réutiliser le CSI passé comme CSI future. C'est la méthode naïve, elle permet de vérifier si nos futures modèles apprennent bien à prédire.

1.2.2 Régression Linéaire

Nous avons implémenté une Régression Linéaire pour établir une base de comparaison supplémentaire. Cette méthode tente de prédire la prochaine réalisation du canal par une combinaison linéaire des 10 états passés. Bien que légère, cette approche est très robuste sur le dataset fournit puisque les données ont une forte corrélation temporelle.

1.2.3 ConvLSTM + U-Net

Cette solution traite le CSI comme une séquence d'images. Nous nous sommes inspirées d'un article scientifique sur le sujet.(CSI Prediction Using Diffusion Models) Cette architecture combine deux blocs puissants :

- ConvLSTM (Temporal Encoder) : Le ConvLSTM intègre des convolutions dans ses transitions d'état, il capture simultanément les corrélations temporelles et spatiales.
- U-Net : Utilisé en sortie de l'encodeur, l'U-Net est un modèle de diffusion. Grâce à ses skip connections, il préserve les détails fins de la structure du canal, garantissant que la prédiction est la plus proche possible du canal réel.

1.2.4 ConvLSTM + Attention Canal + Dense

Cette architecture hybride un ConvLSTM pour la dynamique temporelle à un module d'Attention Canal qui recalibre les poids des antennes les plus significatives. Une tête de prédiction Dense effectue ensuite la régression finale.

1.2.5 Conv3D + Spatio-Channel Attention

C'est notre modèle le plus performant. Il utilise des convolutions 3D pour extraire simultanément les caractéristiques sur les dimensions temporelles, fréquentielles et spatiales. L'ajout d'un mécanisme d'Attention Spatio-Canal permet au modèle de se focaliser dynamiquement sur les informations les plus pertinentes.

2 Qualité technique et faisabilité

2.1 Choix technologiques et architecture des modèles

L'ensemble de ces modèles (ConvLSTM, Conv3D, U-Net) ont été choisis pour leur capacité complémentaire à capturer les dépendances multidimensionnelles du canal CSI. Plus précisément, ces architectures permettent d'extraire simultanément les corrélations temporelles liées à la mobilité, les corrélations spatiales entre les antennes du Massive MIMO et les structures fréquentielles des données.

2.1.1 ConvLSTM + U-Net

- Le **ConvLSTM** contrairement à un LSTM standard qui utilise des produits scalaires, le ConvLSTM remplace ces derniers par des convolutions. Cela permet de capturer les corrélations spatiales entre les antennes tout en maintenant une mémoire à long terme de l'évolution du canal.
- **Bloc U-Net** :
  - **Encodeur** : Composé de successions de convolutions et de Pooling. Son rôle est de réduire la dimensionnalité pour extraire les caractéristiques abstraites et globales du canal.
  - **Bottleneck** : La couche la plus profonde qui contient la représentation latente compressée de la dynamique du signal.
  - **Décodeur** : Utilise des convolutions transposées pour reconstruire la matrice CSI à sa taille d'origine.
  - **Skip Connections** : C'est l'élément clé du U-Net. Elles copient les cartes de caractéristiques de l'encodeur directement vers le décodeur. Leur rôle est de préserver les détails spatiaux fins et les hautes fréquences du signal qui auraient été perdus lors de la compression, garantissant une reconstruction fidèle des phases du canal.

2.1.2 Conv3D + Spatio-Channel Attention

- **Conv3D** : Cette architecture est similaire au ConvLSTM mais utilise non pas des convolution 2D mais 3D pour capturer les corrélations temporelles.
- **Bloc d'Attention Spatio-Canal** :
  - **Attention Spatiale** : Ce module génère une carte d'activation permettant au modèle de focaliser son apprentissage sur les antennes les plus significatives du système Massive MIMO. Son rôle est d'identifier les zones de la matrice de canal ayant le plus fort impact sur la qualité du signal.
  - **Attention Canal (Channel)** : Elle recalibre les poids des différentes cartes de caractéristiques en exploitant les interdépendances entre elles. Son rôle est de filtrer les composantes bruitées pour ne conserver que les fréquences portant l'information structurelle du canal.

2.2 Méthodologie d'entraînement et robustesse

La robustesse de nos modèles repose sur un pipeline de données rigoureux :

- **Prétraitement :** Normalisation des données CSI (données complexes) et segmentation en fenêtres glissantes pour l'apprentissage supervisé.
- **Fonction de perte :** Nous utilisons l'Erreur Quadratique Moyenne (MSE) comme métrique principale, minimisant la distance entre le canal prédit et le canal réel fourni par le dataset Nokia.
- **Optimisation :** Utilisation de l'optimiseur Adam avec un ordonnanceur de taux d'apprentissage (Learning Rate Scheduler) pour garantir une convergence stable et éviter les minima locaux.

2.3 Faisabilité et scalabilité

Globalement, les modèles que nous avons conçus sont de grande taille et requièrent une quantité importante de données. Par ailleurs, en raison de la taille importante des modèles, l'entraînement nécessite une durée de l'ordre d'une dizaine de minutes pour quelques époques avec un petit dataset. On peut donc penser que pour un gros dataset, il est assez coûteux d'entrainer nos modèles.

2.4 Résultats

Après avoir entrainé et testé nos différents modèles sur un même dataset, le Conv3D obtient les meilleurs résultats. On remarque que le Conv3D à des résultats légèrement meilleur que les autres convolutions. Enfin le modèle de régression reste pertinent. Cela peut s'expliquer par la forte corrélation temporelle du dataset et une variance très peu forte.

3 Impact, risques et responsabilité

3.1 Impact sociétal et environnemental

L'optimisation du feedback CSI par l'IA a un impact direct sur l'efficacité des réseaux mobiles :

- **Efficacité énergétique** : En réduisant l'overhead de signalisation, on diminue l'activité radio nécessaire, ce qui contribue à la sobriété énergétique des infrastructures 5G/6G.
- **Amélioration de la connectivité** : Une meilleure prédiction du canal permet une adaptation dynamique aux conditions environnementales, garantissant une connexion plus stable et performante pour les utilisateurs.

3.2 Analyse des risques et limites techniques

Malgré les performances de nos modèles, plusieurs risques doivent être maîtrisés :

- **Complexité computationnelle** : Nos architectures (Conv3D, U-Net) sont volumineuses et exigent une puissance de calcul importante. Cela peut poser un défi pour une implémentation sur des terminaux mobiles ayant des contraintes de batterie.
- **Dépendance aux données** : La précision de la prédiction repose sur un volume massif de données. Un modèle entraîné sur un dataset spécifique pourrait perdre en fiabilité s'il est confronté à un environnement de propagation radicalement différent de celui d'entraînement.

4 Conclusion et recommandations

4.1 Synthèse des apports du projet

Ce projet a permis de démontrer l'efficacité de l'IA générative et des réseaux de neurones profonds pour résoudre le défi de la prédiction du canal CSI. En comparant des architectures allant de la Régression Linéaire aux modèles Conv3D avec Attention. Nos architectures capturent avec précision les dépendances spatio-temporelles du CSI, offrant une solution concrète pour réduire l'overhead de signalisation dans les réseaux 5G/6G.

4.2 Limites identifiées

Malgré des résultats prometteurs, deux limites majeures subsistent pour un déploiement immédiat :

- **Complexité matérielle** : La taille des modèles (U-Net, Conv3D) nécessite des ressources de calcul et de mémoire importantes, ce qui peut impacter l'autonomie des terminaux mobiles.
- **Temps d'apprentissage** : La lourdeur des entraînements limite pour l'instant la capacité du système à se réadapter en temps réel à des changements d'environnement brusques.

4.3 Perspectives

- Une évolution majeure consisterait à prédire non pas un seul état futur, mais une séquence complète de CSI afin d'anticiper la trajectoire du canal à plus long terme.
- Compte tenu de la taille importante de nos architectures (Conv3D, U-Net), l'application de techniques de pruning est essentielle pour réduire l'empreinte mémoire et la consommation d'énergie sur les terminaux mobiles.
- Hybridation avec la compression (Autoencoders) : Combiner nos prédicteurs avec des architectures d'auto-encodeurs permettrait de ne transmettre que le "résidu" (la différence entre le canal réel et la prédiction), minimisant ainsi l'overhead de signalisation au strict minimum nécessaire.